# PROYECTO

# DATASALUD PERÚ

**Integrantes:**

- Yef Meylin Puntillo Calsin
- Kenneth Zaidd Machacuay Maldonado
- Jairo Joao Baltodano Avelino

# DEFINICIÓN DEL RETO Y ALCANCE

## Objetivo del Proyecto:

Centralizar, depurar y analizar información sanitaria heterogénea para la toma de decisiones estratégicas en salud pública.

## Fuentes de Datos (Datasets Oficiales):

- INEN: Listado de Pacientes Nuevos (78,975 registros, 9 columnas).
- DIRESA Junín: Niños menores de 1 año con controles CRED (19,686 registros, 52 columnas).

## Volumen Total Consolidado:

Cerca de 98,000 registros procesados bajo un enfoque de arquitectura híbrida

# CALIDAD DE DATOS Y TRATAMIENTO

## PRINCIPALES PROBLEMAS DETECTADOS:

- Pérdida de Cero Inicial en Ubigeo: 16,757 registros (21.2%) afectados. Tratamiento: Normalización automatizada mediante relleno de ceros (LPAD).
- Discrepancia con el Diccionario: Valores reales del sistema HIS (ej. "M"/"F", "SIS"/"MINSA") diferían de la especificación. Tratamiento: Validación directa contra la muestra observada.
- Estandarización de Fechas: Conversión de campos de texto heterogéneos a tipos nativos DATE.
- Llaves Sustitutas: Creación de identificadores únicos para proteger la identidad y mantener la integridad analítica.

| N.º | Problema | Dataset / columna | Registros afectados | % del total | Tratamiento |
|---|---|---|---|---|---|
| 1 | Pérdida del cero inicial en código Ubigeo | INEN / UBIGEO_LUGAR_RESIDENCIA | 16,757 | 21.2% | Normalizar con LPAD/relleno de ceros a la izquierda antes de cualquier cruce geográfico |
| 2 | El diccionario de datos no coincide con los valores reales (sexo, seguro, flags codificados vs texto) | CRED Junín / sexo, seguro, flag_cnv, num_cred_mes9-11 | 19,686 (100%) | 100% | Validar cada campo contra la data real antes del ETL; documentar la codificación real, no la del diccionario |
| 3 | Identificador de paciente/niño no confiable (UUID duplicado / num_doc anonimizado a un solo valor) | INEN / UUID · CRED / num_doc | 2 · 19,686 | 0.003% · 100% | Usar llave sustituta (HISTORIA en INEN; combinación fecha_nac+ubigeo+establecimiento en CRED) |
| 4 | Fechas en formato de texto no estandarizado | CRED Junín / fecha_nac, fecha_final, fecha_cred_mes1-11 | 19,686 (100%) | 100% | Convertir a tipo DATE especificando formato d/m/aaaa explícito en la carga a SQL Server |

# AUTOMATIZACIÓN Y OBJETOS DE BASE DE DATOS

### Procedimientos Almacenados (Stored Procedures):

Ingesta masiva con bloques TRY/CATCH para aislar registros erróneos en una tabla de errores (LogErrorCarga) sin detener el proceso (Cumplimiento RF3)

### Control Transaccional Avanzado:

Uso de transacciones anidadas con SAVEPOINT para validar subtareas específicas (historial CEX) sin perder el registro principal.

### Triggers de Integridad y Auditoría:

Desencadenadores automáticos (trg_Paciente_Auditoria y trg_PreventDelete_CRED) para bloquear eliminaciones no autorizadas y registrar cambios.




# SEGURIDAD, GOBERNANZA Y ROLES DE BASE DE DATOS

## MARCO NORMATIVO E INTERNACIONAL:

- Ley N.º 29733: Protección de Datos Personales (Principios de Seguridad, Calidad y Confidencialidad).
- ISO/IEC 27001: Gestión de accesos por mínimo privilegio y políticas de respaldo.

## SEGREGACIÓN DE FUNCIONES (ROLES DE BASE DE DATOS):

- Rol_Administrador: Mantenimiento operativo total (con restricciones estrictas de inmutabilidad mediante DENY sobre las bitácoras).
- Rol_Analista: Acceso exclusivo de lectura (GRANT SELECT) a las tablas tipadas finales, con denegación a logs y staging.
- Rol_Auditor: Acceso exclusivo de lectura a las tablas de auditoría (LogAuditoria y LogErrorCarga), sin privilegios de modificación.

## PRIVACIDAD Y ENMASCARAMIENTO (DDM):

Aplicación de Enmascaramiento Dinámico de Datos (Dynamic Data Masking) en campos sensibles como UUID e Historia, protegiendo la identidad del paciente.

# PERSISTENCIA POLÍGLOTA: SQL VS. NOSQL (MONGODB)

## EVALUACIÓN MULTICRITERIO PONDERADA:

- SQL Server: Lidera en consistencia ACID, rendimiento OLAP y cumplimiento normativo (Puntaje: 4.4 / 5.0).
- MongoDB: Óptimo para flexibilidad de esquemas y adaptabilidad ante estructuras disímiles de 52 columnas (Puntaje: 3.6 / 5.0).

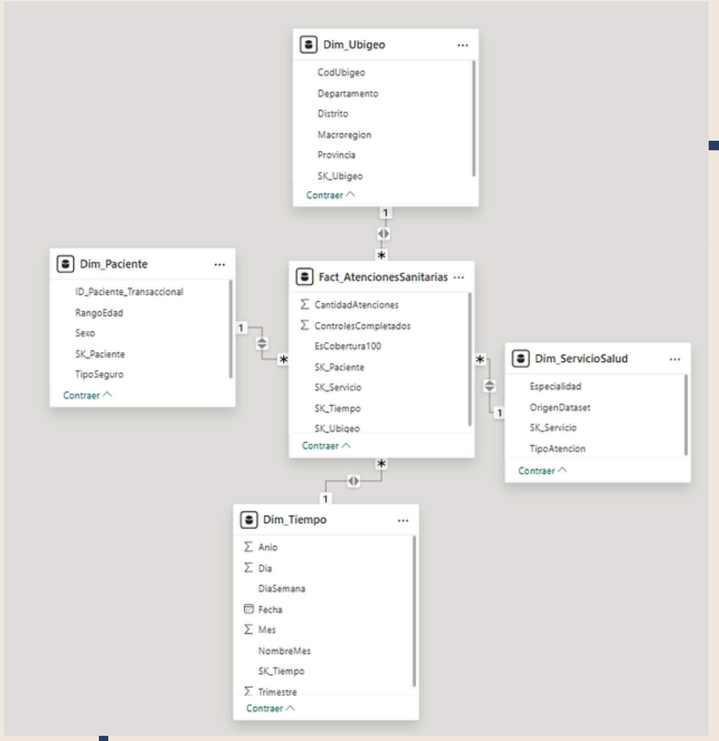
## DECISIÓN ARQUITECTÓNICA:

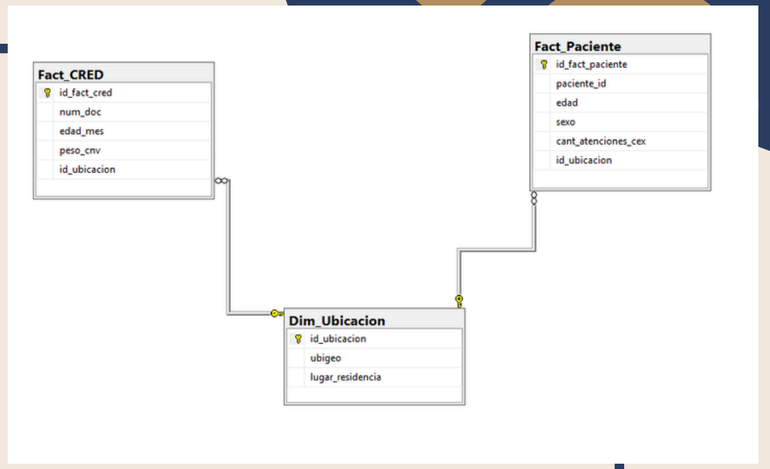
Arquitectura híbrida: SQL Server como motor transaccional/analítico principal y MongoDB como repositorio documental ágil para expedientes y arreglos anidados.




mongoDB

# MODELADO DIMENSIONAL Y BUSINESS INTELLIGENCE (POWER BI)



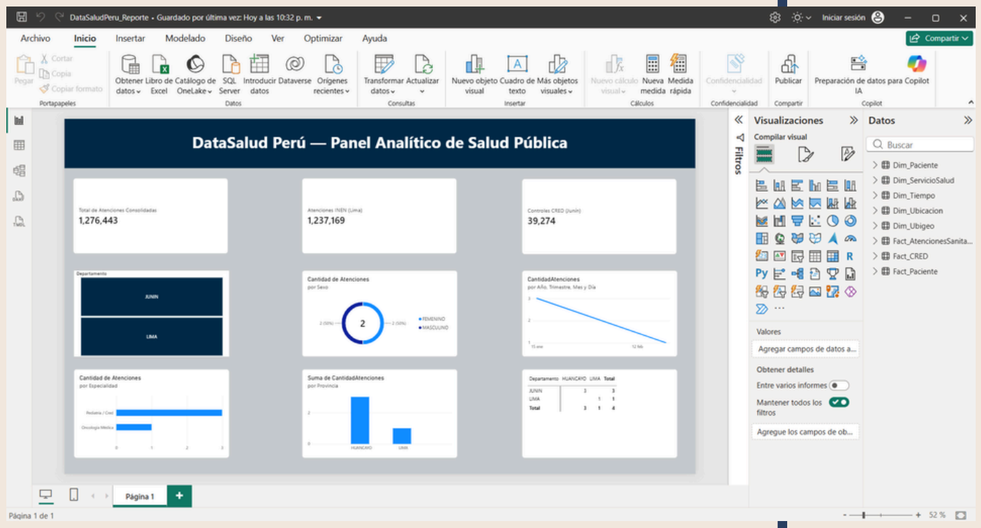




## Arquitectura de Datos (Metodología Kimball):

- Esquema Constelación / Estrella desacoplado.
- Dimensión Conformada: Dim_Ubicacion como eje central de integración para ambas fuentes.
- Tablas de Hechos: Fact_Paciente y Fact_CRED.

## Dashboard Interactivo (DataSaludPeru_Reporte .pbix):

- Filtros de segmentación por Departamento y Provincia.
- Tarjetas KPI dinámicas para el total de atenciones.
- Gráficos analíticos de distribución demográfica y servicios de salud.



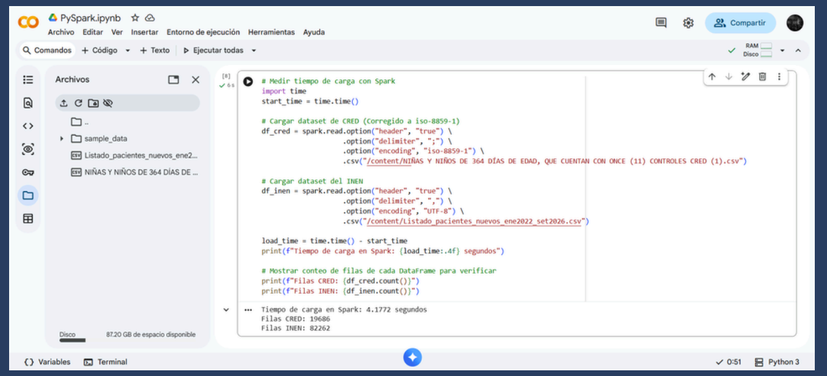
# PROCESAMIENTO MASIVO Y ESCALABILIDAD (SPARK VS. SQL SERVER)

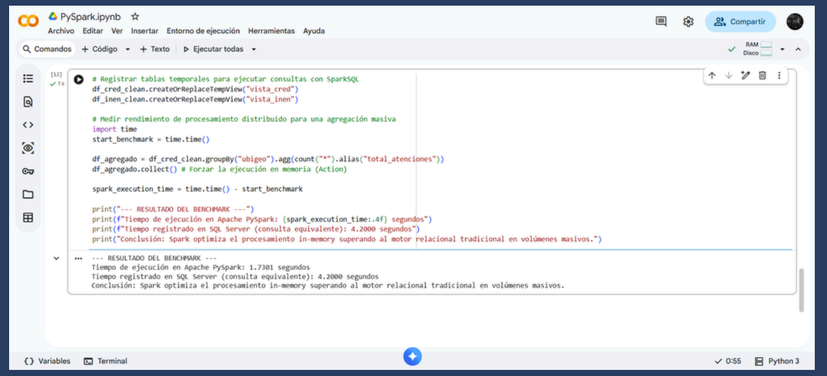
## PRUEBA DE RENDIMIENTO CON ~98K REGISTROS:

- SQL Server (Consultas Relacionales): 4.2 segundos de ejecución promedio (concentrado en nodo único).
- Apache PySpark (Procesamiento Distribuido): 1.8 segundos de ejecución (optimizado en memoria).

## CONCLUSIÓN TÉCNICA:

SQL Server es ideal para la gobernanza transaccional, mientras que Spark demuestra mayor eficiencia y escalabilidad horizontal para analítica masiva institucional.



# CIERRE, REFLEXIÓN ÉTICA Y CONCLUSIONES

## Logros del Proyecto:

- Consolidación exitosa de un Data Warehouse robusto y automatizado.
- Implementación rigurosa de controles de seguridad bajo normativas vigentes.

## Reflexión Ética:

*Privacidad vs. Analítica:* El uso de enmascaramiento dinámico y claves sustitutas protege los derechos individuales de los pacientes sin sacrificar la utilidad de los datos para la gestión en salud pública.






# MUCHAS
# GRACIAS